


TP558 - Tópicos avançados em Machine Learning: Convolutional Vision Transformer (CvT)



Introdução

CvT: Introducing Convolutions to Vision Transformers

Haiping Wu^{1,2*} Bin Xiao^{2†} Noel Codella² Mengchen Liu² Xiyang Dai²
Lu Yuan² Lei Zhang²
¹McGill University ²Microsoft Cloud + AI

O Artigo apresenta o Convolutional vision Transformer (CvT), uma nova arquitetura de rede neural que aprimora o **Vision Transformer (ViT)** ao integrar estrategicamente operações de convolução para aumentar o desempenho e a eficiência. Essa integração permite que o CvT herde características das **Redes Neurais Convolucionais (CNNs)**, como invariância à translação e escala, e ao mesmo tempo mantenha a atenção dinâmica dos Transformers.

Introdução

O Cenário dos Transformers em Visão Computacional

- **Transformers:** Originalmente dominantes em Processamento de Linguagem Natural (PNL).
 - Conhecidos por capturar dependências de longo alcance e contexto global.
- **Vision Transformer (ViT):** O primeiro a aplicar exclusivamente a arquitetura Transformer para classificação de **imagens em larga escala**, alcançando desempenho competitivo.
 - **Como funciona:** Decompõe uma imagem em sequências de "patches" (tokens) não sobrepostos de tamanho fixo, que são então processados por **camadas Transformer com módulos de autoatenção multi-cabeça** (MHSA) e redes feed-forward (FFN).

Introdução

O que São CNNs

- Redes Convolucionais (CNNs): Arquiteturas dominantes em visão por computador que se destacam na captura de estruturas locais.
- Propriedades-chave: Forçam a captura de estruturas locais usando campos receptivos locais, **pesos compartilhados e subamostragem espacial**, o que resulta em invariância a translação, escala e distorção.
- Hierarquia: Aprendem padrões visuais hierarquicamente, de arestas simples a padrões semânticos complexos.

Introdução

O Desafio dos ViTs Puros e as Vantagens das CNNs

Limitações dos ViTs Puros



Viés Indutiva Local Fraco:
Convergência lenta e
necessidade de muitos dados.



**Alto Custo
Computacional:** Memória elevada
para alta resolução.



Alto Custo Computacional:
Memória e custo elevados alta
resolução.

**Dependence de Positional
Embeddings:** Design para resolução variável.

Vantagens das CNNs



Viés Indutiva Local Forte:
Captura eficiente
características locais.



Eficiência:
Convergência rápida mesmo
com poucos dados.



Eficiência:
Convergência mesmo com
poucos dados.


Estrutura Hierárquica: Aprende
padrões em vários níveis de complexidade.

Introdução

A resposta está em uma arquitetura híbrida: o **Convolutional vision Transformer (CvT)**.


Em vez de apenas tokens, ele usa convoluções, que são especialistas em capturar os **detalhes locais**, como as **texturas e as bordas de um objeto**.

O resultado é uma IA que, assim como nós, vê o quadro geral (atenção global) e também se atenta aos detalhes (contexto local), tornando-se mais eficiente e poderosa.



Arquitetura e funcionamento

Hierarquia de Transformers com Embedding Convolucional de Tokens




Benefícios:

- Captura de Informações Locais: Essencial para modelar contextos espaciais, desde bordas de baixo nível até primitivas semânticas de ordem superior, em uma abordagem hierárquica.
- Downsampling Eficiente: Reduz progressivamente o comprimento da sequência de tokens e aumenta a dimensão das características entre os estágios, semelhante ao que ocorre nas CNNs


Arquitetura e funcionamento

Arquitetura do CvT: Principais Inovações (I)



A Figura 1 mostra o pipeline (fluxo de processamento) geral, enfatizando a estrutura hierárquica em três estágios.


Arquitetura e funcionamento



A Figura 1 (A), enfatiza a estrutura hierárquica em três estágios.

Arquitetura e funcionamento

Estágio no CvT



ESTÁGIO	OPERAÇÃO INICIAL	RESULTADO APROXIMADO
ESTÁGIO 1	Incorporação de Tokens Convolucionais (<i>Convolutional Token Embedding</i> - CTE) sobre a imagem de entrada (224 x 224)	<i>Tokens</i> $\approx 56 \times 56$ com 64 canais
ESTÁGIO 2	CTE sobre os tokens anteriores (<i>downsampling</i> com <i>stride</i> 2)	<i>Tokens</i> $\approx 28 \times 28$ com 192 canais
ESTÁGIO 3	Novo CTE (<i>stride</i> 2)	<i>Tokens</i> $\approx 14 \times 14$ com 384 ou mais canais

Cada Estágio faz duas coisas:

- **Reduz a resolução espacial** (menos *tokens*, mais compactos).
- **Aumenta a dimensão das características** (mais canais por *token*, mais informação semântica).

Arquitetura e funcionamento

Arquitetura do CvT: Principais Inovações (I)


A parte (b) da figura mostra como o CvT modifica o bloco Transformer clássico.

Em vez de usar multiplicações lineares para obter Q, K e V, ele utiliza convoluções separáveis em profundidade (depth-wise separable convolutions), que respeitam a estrutura espacial dos tokens.

Isso permite que o modelo capture informações local e global ao mesmo tempo, além de torná-lo mais eficiente.

Além disso, como as convoluções já incorporam a posição, o CvT não precisa de positional embeddings (incorporações posicionais).

Este bloco — chamado Bloco Transformer Convolutacional (Convolutional Transformer Block) — é repetido várias vezes dentro de cada estágio do CvT, sendo o coração do processamento hierárquico.




Arquitetura e funcionamento

Arquitetura do CvT: Principais Inovações (II)

- **2. Bloco do Transformer Convolucional com Projeção Convolucional**
- **Função:** A projeção linear padrão, utilizada antes de cada bloco de autoatenção em um Transformer para Q (query), K (key) e V (value), é substituída por uma **projeção convolucional**.
- **Mecanismo:** Emprega uma convolução separável em profundidade (**depth-wise separable convolution**) de tamanho $s \times s$ em um mapa de tokens 2D.
- **Benefícios de Eficiência:**
 - **Contexto Local Aprimorado:** Captura ainda mais contexto espacial local e reduz a ambiguidade semântica no mecanismo de atenção.
 - **Redução de Custo Computacional:** **Permite a subamostragem das matrizes K e V utilizando um stride maior que 1** (por exemplo, stride de 2, reduzindo 4x o custo). Isso resulta em uma melhoria de eficiência de 4x ou mais na operação MHSA, com degradação mínima de desempenho.
 - As convoluções compensam a perda de informação causada pela redução de resolução.

Arquitetura e funcionamento


Arquitetura do CvT: Principais Inovações (II)



A Figura 2 compara três maneiras de gerar Q, K e V. **No ViT clássico (a)**, as projeções são lineares e independentes, sem noção espacial. **No CvT (b)**, cada projeção é feita com uma convolução 2D, de modo que cada token incorpora informação local da vizinhança. **A versão comprimida (c)** usa $\text{stride} = 2$ para K e V, reduzindo a resolução e o custo de cálculo, mas mantendo a precisão. Assim, o **CvT** une o melhor das CNNs (percepção local e hierarquia) com o poder global dos Transformers.

Arquitetura e funcionamento

Arquitetura do CvT: Principais Inovações (II)




(a)

- **(a) Linear Projection (ViT clássico)**
- Esta parte mostra como o **Vision Transformer original (ViT)** calcula as matrizes de atenção **Q**, **K** e **V**:
- A imagem é dividida em pequenos patches, transformados em uma **sequência de tokens** (os quadradinhos rosados).
- Cada token é multiplicado por uma matriz de pesos diferente para gerar:
 - **Q** (*query*),
 - **K** (*key*),
 - **V** (*value*).

Arquitetura e funcionamento


Arquitetura do CvT: Principais Inovações (II)



- **(b) Convolutional Projection**
- Em vez de multiplicar cada token separadamente, o CvT:
 - **Reestrutura** os tokens em formato 2D (um mapa de tokens).
 - **Aplica uma convolução 2D** com uma janela $s \times s$.
 - **Desliza essa janela** sobre toda a imagem com *stride* = 1.
 - Gera novos mapas para **Q**, **K** e **V**, que são depois achatados (*flatten*) e enviados para o mecanismo de atenção.

Arquitetura e funcionamento

Arquitetura do CvT: Principais Inovações (II)




(c)

- **(c) Projeção convolucional comprimida**
- Q é calculado como antes ($stride = 1$).
- K e V são obtidos com **stride = 2**, o que:
 - **Reduz** a resolução espacial dos mapas K e V (por exemplo, de 56×56 para 28×28).
 - **Diminui** o número de tokens a serem comparados na atenção.
- As janelas de K e V pulam posições ($stride = 2$).
- Os mapas gerados são menores e, portanto, **“espremidos”**.
- Todos são achatados no final, como no caso anterior.

RESULTADOS

- **Vantagens e Desempenho**
- **Desempenho de Ponta e Eficiência:** O CvT atinge um desempenho superior aos Vision Transformers e ResNets existentes na classificação ImageNet-1k, utilizando menos parâmetros e FLOPs.
- **Invariância Reforçada:** Herda propriedades desejáveis das CNNs, como invariância a deslocamento, escala e distorção.
- **Remoção de Positional Embeddings:** Uma vantagem significativa é que o CvT **não requer embeddings posicionais explícitos**.
 - As convoluções incorporadas permitem que a rede modele relações espaciais localmente.
 - Simplifica o design e facilita a adaptação para tarefas de visão com resoluções de entrada variáveis, sem a necessidade de re-projeto do embedding.
- **Estrutura Hierárquica e Representação Rica:** O design multiestágio com convoluções permite downsampling espacial e o aprendizado de padrões visuais mais complexos em áreas espaciais maiores, similar às camadas de características das CNNs.
- **Convergência Rápida:** Demonstra uma convergência significativamente mais rápida durante o treinamento em comparação com modelos Transformer originais.

RESULTADOS




- Acurácia Top-1 no ImageNet validação comparada a outros métodos em relação aos parâmetros do modelo.

A Figura ilustra que a **introdução estratégica de convoluções** na arquitetura Transformer (CvT) permite combinar os melhores atributos das Redes Neurais Convolucionais (CNNs) e dos Transformers. Isso resulta em modelos que consistentemente atingem **maior acurácia Top-1** no ImageNet com **menos parâmetros e menores FLOPs** (operações de ponto flutuante).

RESULTADOS

A. Desempenho em Grande Escala (Pré-treinamento no ImageNet-22k)


ARQUITETURA	ACURÁCIA TOP-1 (IMAGENET-22K)	PARÂMETROS (M)	TIPO
VIT	85.2%	307 M	Transformer
CVT	87.7%	277 M	Convolutional Transformer
BIT	85.4%	928 M	CNN (Rede Convolutacional)



O modelo **CvT** pré-treinado no ImageNet-22k atinge uma acurácia Top-1 de **87.7%**. Isso **supera em 2.5%** o desempenho do ViT-L/16 e é mais preciso que o BiT-M, mas o CvT o faz usando significativamente menos parâmetros.

RESULTADOS

B. Comparação com Trabalhos Concorrentes (Pré-treinamento no ImageNet-1k)



CvT-21 vs. DeiT-B: O CvT-21 supera o DeiT-B em 0.7 pontos percentuais (82.5% vs. 81.8%), utilizando uma **redução de 63% nos parâmetros** e uma **redução de 60% nos FLOPs**.

Modelos Leves: O modelo mais leve, **CvT-13** (20 M de parâmetros), alcança 81.6% de acurácia Top-1, superando trabalhos concorrentes como PVT-Small, T2T-ViTt-14 e TNT-S por 1.7%, 0.8% e 0.2% respectivamente.

ARQUITETURA (IMAGENET-1K)	ACURÁCIA TOP-1	PARÂMETROS (M)	FLOPS (G)
CVT-21	82.5%	32 M	7.1 G
DEIT-B	81.8%	86 M	17.6 G
PVT-SMALL	79.8%	25 M	3.8 G

Comparativo: CvT vs. Outras Arquiteturas Híbridas

Comparativo Essencial

Tabela 1: Comparativo: CNNs vs. ViT vs. CvT

Aspecto	CNN	ViT	CvT
Viés Indutivo Local	Forte	Fraco	Forte (via convoluções)
Estrutura Hierárquica	Sim	Não	Sim
Positional Encoding	Não	Requerido	Não Requerido
Mecanismo de Atenção	Nenhum	Autoatenção Global	Autoatenção Convolutacional
Eficiência em Alta Res.	Alta	Baixa	Alta

RESULTADOS

Outros ViTs Híbridos (Exemplos)

- **DETR (Detection Transformer):** Utiliza uma CNN como backbone para extrair mapas de características antes de alimentar um encoder-decoder Transformer para detecção de objetos.
- **PVT (Pyramid Vision Transformer):** Incorpora uma estrutura piramidal multiestágio, semelhante às CNNs, para lidar com mapas de características de alta resolução, usando um módulo de *spatial-reduction attention* (SRA).
- **Conformer:** Combina ramos separados de CNN (para percepção local) e Transformer (para características globais), com conexões entre eles.
- **MaxViT (Multi-Axis Attention-based Vision Transformer):** Adota uma estrutura hierárquica com blocos híbridos que consistem em convoluções MBConv e atenção multi-eixo (local e global).
- **CeiT (Convolution-enhanced Image Transformer):** Modifica o esquema de extração de patches, a camada MLP e adiciona uma camada convolucional final para melhor desempenho.

Exemplo(s) de aplicação

- Aplicações em Visão Computacional
 - **Backbone Versátil:** O CvT serve como um backbone robusto e eficiente para uma ampla gama de tarefas de visão computacional.
 - **Classificação de Imagens:** Sua aplicação primária e onde demonstrou desempenho de ponta (ex: ImageNet-1k, ImageNet-22k).
 - **Detecção de Objetos e Segmentação de Instâncias:** As modificações introduzidas pelo CvT o tornam adequado para tarefas de previsão densa. Exemplos de outros HVTs já mostraram sucesso em Mask R-CNN e Cascade R-CNN.

Vantagens e desvantagens

Vantagens



Desempenho Superior e Eficiência

CvT melhora ViT em permanência e eficiência ao state-of-the-art em permanência e eficiência alcançado pelo imageNet-1k e alcançando o mesmo desempenho entre CNNs e ViTs



Remoção de Positional Embeddings

Elimina a necessidade de embeddings posicionais explícitos sem perda de desempenho, simplificação em tamanho como



Desvantagens



Complexidade de Implementação

A arquitetura híbrida combina CNNs e Transformers, o que pode aumentar a complexidade de implementação e otimização em comparação com modelos puros,



Custo Computacional Ainda mais eficiente que ViTs, ainda herda alguma complexidade quadrática da atenção, podendo ser desafiador e oneroso com recursos limitados ou imagens de alta resolução



Reusabilidade e Tuning O equilíbrio entre componentes convolucionais pode facilitar o uso de tuning cuidadoso, e a reutilização de modelos simples

Validação e Refutação

O **Convolutional Vision Transformer (CvT)** representa um avanço significativo no campo da visão computacional, unindo com sucesso as melhores características das Redes Neurais Convolucionais (CNNs) e dos Vision Transformers (ViTs).

Através do **Embedding Convolucional de Tokens** e da Projeção Convolucional, o CvT incorpora o viés indutivo local das CNNs, mantendo a capacidade de modelagem de contexto global dos Transformers.

Isso resulta em **desempenho superior e maior eficiência**, com menos parâmetros e FLOPs, e a notável capacidade de dispensar positional embeddings, simplificando o design para tarefas de visão de resolução variável.

O CvT é um **backbone versátil** que pavimenta o caminho para o desenvolvimento de modelos de visão computacional mais robustos, eficientes e adaptáveis a um espectro ainda maior de aplicações práticas.

APLICAÇÃO

Galaxy morphology classification based on Convolutional vision Transformer (CvT) ★

Jie Cao¹, Tingting Xu^{1,★★}, Yuhe Deng¹, Linhua Deng^{1,★★★} Mingcun Yang¹, Zhijing Liu¹, and Weihong Zhou^{1,2,★★★★}

APLICAÇÃO





Fig. 2. Convolutional vision Transformer (CvT) structure.

APLICAÇÃO


A implementação do CvT está disponível no [GitHub](#).

Este subconjunto de cinco classes foi selecionado como foco da aplicação do modelo Convolutional vision Transformer (CvT) para classificação e estudo .




APLICAÇÃO

A Figura apresenta imagens de **cinco grupos de galáxias** selecionadas do **dataset Galaxy Zoo CANDELS**, um conjunto de dados utilizado para estender os experimentos para a classificação de galáxias de **alto *redshift***. A seleção destes grupos teve como objetivo verificar a **eficácia do modelo CvT** na classificação de imagens de alto *redshift* e inclui diversas características morfológicas e estágios de desenvolvimento:



APLICAÇÃO

- **Grupo 6:** Galáxias **elípticas** (sem braços espirais), com coloração que varia do amarelo ao branco-amarelado pálido, indicando **antiguidade galáctica** (tipo inicial).
- **Grupo 8:** Galáxias **espirais** com cores em tons de **azul**, sinalizando **formações galácticas mais jovens** (tipo tardio).
- **Grupo 11:** Galáxias **espirais** com braços acentuados, mas com uma **paleta avermelhada** que sugere **formas galácticas mais antigas** (tipo inicial).
- **Grupo 16:** Galáxias **irregulares** de coloração **azul**, denotando **formação estelar ativa** (tipo tardio).
- **Grupo 45:** Galáxias **irregulares** com um **tom avermelhado**, classificadas como galáxias de **tipo inicial**.



APLICAÇÃO

Table 4. Comparison of classification results under different levels of Gaussian noise and salt-and-pepper noise by different models.

Reference	Model	Add noise type	Add noise level	Accuracy
this work	CvT-13	Gaussian noise	sigma=0	0.988
			sigma=5	0.931
			sigma=25	0.864
			sigma=50	0.837
		salt-and-pepper noise	amount=0	0.988
			amount=0.05	0.902
			amount=0.1	0.831
			amount=0.2	0.815
[1]	EfficientNet-B5	Gaussian noise	sigma=0	0.968
			sigma=5	0.783
			sigma=20	0.847
			sigma=50	0.815

References. [1] [Ai et al. \(2022\)](#)

APLICAÇÃO

Visualização dos resultados da classificação morfológica de galáxias obtidos pelo modelo CvT

O resultado principal demonstrado na Figura 10 é que os clusters de várias galáxias possuem limites claros e distintos, o que sugere que o modelo CvT alcança um bom desempenho na classificação da morfologia galáctica.




Fig. 10. Visualization of CvT classification results.

APLICAÇÃO

Reference	Model	Accuracy	Precision	Recall	F1_Score
[1]	ResNet-26	0.952	0.951	0.952	0.952
[2]	ViT B/16	0.946	0.941	0.942	0.941
[3]	EfficientNet-B5	0.968	0.967	0.968	0.967
[4]	NODE	0.917	0.916	0.934	0.926
[5]	MSCCN	0.970	0.961	0.982	0.964
this work	CvT-13	0.988	0.981	0.980	0.980

Table 8. Comparison of computational and memory use between CvT-13 and ViT B/16.

Model	Params(M)	FLOPs(G)
ViT B/16	86.4	55.5
CvT-13	20	4.5

QUIZ



[QUIZ SEMINARIO](#)

[GITHUB](#)

Referências

- [1] Haiping Wu, Bin Xiao, Noel Codella, Mengchen Liu, Xiyang Dai, Lu Yuan, and Lei Zhang. Cvt: Introducing convolutions to vision transformers. *arXiv preprint arXiv:2103.15808*, 2021.
- [2] Li Yuan, Qibin Hou, Zeming Li, Jiashi Feng, and Shuicheng Yan. Tokens-to-token vit: Training vision transformers from scratch on imagenet. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 558–567, 2021.
- [3] Yanghao Tu, Zhicheng Cai, Zhibin Wang, Yichen Liu, and Dahua Lin. Maxvit: Multi-axis vision transformer. In *European Conference on Computer Vision*, pages 3–20. Springer, 2022.
- [4] Li Yuan, Shi Pu, Francis EH Tay, and Jiashi Feng. Ceit: Convolution-enhanced image transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 101–110, 2022.
- [5] Yixuan Chen, Zhen-Ya Sun, Xu-Kang Zhang, and Yi-Liang Liu. Galaxy morphology classification based on convolutional vision transformer. *Astronomy & Astrophysics*, 2024.

Obrigado!